

ESS 배터리 수명 예측 : EDA 기반 모델 전략

DS Mini Project · DAY 1 모델 전략 수립

데이터 : MIT-Stanford Battery Dataset (Severson et al., Nature Energy 2019)

Batch 1 (2017-05-12) · Batch 2 (2018-02-20) · Batch 3 (2018-04-12)

울산 4반 · 이채목 · 이진우

목차

1. 분석 설계

분석 목적 · 변수 정의 · 가설

데이터 구조와 품질 점검

수명값 검증과 셀 정리

2. EDA (Batch 1 · 2 · 3 비교)

Q1 Cycle Life 분포 (2장)

Q2 열화 곡선 (2장)

Q3 $\Delta Q(V)$ 곡선 (2장)

Q4 충전 조건과 수명 (2장)

Q5 상관관계 · 다중공선성 (2장)

배치 간 입력 분포 차이

3. 모델 전략

EDA 시사점과 전략의 연결

태스크 · 타깃 · 피처 세트

후보 모델과 선택 근거

사전 점검 (Batch 1 교차검증)

파이프라인과 검증 설계

위험 요인과 DAY 2 계획

코드 : github.com/97-99-02/ess-battery-project

[notebooks/01_EDA.ipynb](#), [02_feature_engineering.ipynb](#)

1 분석 설계 : 목적 · 변수 정의 · 가설

ISSUE) 무엇을 왜 예측하는가

항목	정의
분석 목적	초기 100 사이클 데이터로 셀의 수명(cycle life)을 예측해, ESS 배터리 교체 시점을 수명 종료 전에 계획할 수 있게 한다 (노선 : 교체 비용 = CAPEX 30~40%)
분석 단위	셀 1개 = 1행 (Batch 1 41개, Batch 2 39개, Batch 3 40개)
Y (종속)	cycle_life : 방전 용량이 0.88Ah (공칭 1.1Ah 의 80%) 아래로 처음 내려간 사이클. 연속형 · 비율척도
X (독립) 후보	충전 정책 C1(Q1%)-C2 → C1·Q1·C2·평균 C-rate (연속형), newstructure 여부 (이진) 사이클 요약 : QD, QC, IR, Tmax·Tavg·Tmin, chargetime 사이클 곡선 : Qdlin·Tdlin (전압축 1000점) → ΔQ(V) 통계량
사용 범위	cycle 100 까지 (예측 시점 이후 정보는 쓰지 않음)

가설	EDA 결과
H1. 고속 충전일수록 수명이 짧다	Batch 1 에서 성립 ($r = -0.78$). Batch 2·3 은 평균 충전 속도가 모두 4.8C 라 같은 방식으로 검증 불가 (Q4)
H2. 초기 100 사이클의 용량 값만으로는 수명이 갈리지 않는다	성립. cycle 2 용량과 $r = 0.04$, 100 사이클까지 변화 중앙값 +0.22% (Q2)
H3. 초기 방전 곡선의 변화 ΔQ(V) 가 수명과 연관된다	성립. $\log \text{var}(\Delta Q)$ $r = -0.81 \sim -0.95$, 세 배치 공통 (Q3)
H4. 배치마다 분포가 달라 Batch 1 의 관계가 그대로 옮겨가지 않을 수 있다	성립. Batch 2 수명 30개가 학습 범위 아래, 용량 계열 입력이 $\pm 2\sigma$ 밖 (Q1, 입력 분포)

1 데이터 구조와 품질 점검

ISSUE) 원본이 어떤 형태이고 어디에 결함이 있는가

층위	내용 (셀마다)
셀 정보	cycle_life, policy_readable (충전 정책), barcode, channel_id
summary	사이클별 스칼라 8개 : cycle, QDischarge, QCharge, IR, Tmax, Tavg, Tmin, chargetime
cycles	사이클별 시계열 : t, V, I, T, Qc, Qd, discharge_dQdV, Qdlin·Tdlin (전압축 보간 1000점)
Vdlin	공통 전압축 3.5V → 2.0V, 1000점 (세 배치 동일)

원본 .mat (MATLAB v7.3 / HDF5) 3개 합계 8.3GB → summary 전체 + 앞 120 사이클의 Qdlin·Tdlin 만 셀 단위 pickle 로 변환 (265MB). src/preprocess.py

점검 항목 (cycle ≥ 2, 사용 셀)	Batch 1	Batch 2	Batch 3
사이클 수	34,300	22,995	41,200
QD 스파이크 (<0.5 또는 >1.3Ah)	2	0	0
내부저항 IR = 0 (미측정)	18	4,439	0
chargetime 이상 (≤0, >60분)	6	10	0
Tavg 범위 밖 (<20, >50°C)	0	0	0
cycle 2~100 에서 2% 넘는 일시적 용량 급락이 있는 셀	0	8	0

- Batch 2 의 IR 0 은 셀 6개 (c41~c46) 가 전 구간 기록하지 않은 것이다.
- Batch 2 의 용량 급락 구간은 cycle 46~75 사이에 있어, 피쳐 계산에 쓰는 cycle 2 · 10 · 91~100 과 겹치지 않는다.
- Batch 1 은 cycle 1 이 비어 있다 (QD = 0, Qdlin 없음).

시사점 스파이크는 0.5~1.3Ah 범위 밖 값을 걸추 처리하고, 피쳐는 cycle 2 부터 계산한다. 내부저항은 테스트 배치(Batch 2)에서 셀 단위로 통째로 빠져 있어 최종 피쳐에서 제외한다.

1 수명값 검증과 셀 정리


ISSUE) 타킷이 정의대로 들어 있는가

배치	원본	제외	사용	비고
Batch 1 2017-05-12	46	5 : 80% 미도달 (c8·c10·c12·c13·c22)	41	c0~c4 수명 보정 (+208 ~ +1060)
Batch 2 2018-02-20	47	8 : 수명값 없음 (VarCharge 4, SLOWCYCLE 4)	39	9개가 newstructure 셀
Batch 3 2018-04-12	46	6 : 공식 저장소 noisy 셀 (2개는 수명값 없음)	40	전부 newstructure 셀

제외·보정 기준 : 논문 공식 저장소 Load Data.ipynb (rdbraatz/data-driven-prediction-of-battery-cycle-life-before-capacity-degradation)

- Batch 1·3 은 0.88Ah 에 닿기 직전 사이클에서 기록이 끝나고 cycle_life = 마지막 사이클 + 1 이다. Batch 2 는 기록이 이어지며 cycle_life 가 0.88 첫 하회 사이클과 일치했다.
- Batch 1 c0~c4 는 최소 용량 0.97~1.04Ah 에서 기록이 끝났다. 2017-06-30 배치 에서 측정이 이어진 셀이므로 공식 저장소의 추가 사이클 수를 더했다. 원본값을 그대로 쓰면 가장 긴 셀(c2)의 수명이 2237 이 아니라 1177 로 들어간다.
- Batch 2(2018-02-20)는 논문이 학습·평가에 쓴 124개 셀(2017-05-12, 2017-06-30, 2018-04-12)에 들어 있지 않다. 원 출처는 이 파일을 Figure 4 용 저속 데이터로 분류한다.

시사점 수명 보정·셀 제외를 전처리 단계에 고정한다. Batch 2 는 원논문 테스트셋과 다른 셀이므로 원논문 성능(9.1%)과의 Gap 은 테스트셋이 다르다는 전제로 해석한다.



배치	중앙값	범위	<500	>1000	<550 셀 수
Batch 1	842	534 ~ 2237	0%	24%	1
Batch 2	472	392 ~ 1186	72%	8%	30
Batch 3	964	541 ~ 1935	0%	48%	1


확인한 내용

- Batch 1 은 600~1000 에 몰려 있고 1400~2237 에 긴 꼬리 (5개)가 있다.
- Batch 2 는 두 덩어리로 갈린다. 일반 셀 30개는 392~514, newstructure 셀 9개는 777~1186 이다. 일반 셀 30개 전부가 Batch 1 최솟값(534)보다 짧다.
- Batch 1 에서 가장 짧은 두 셀(534, 559)은 5.4C(80%)-5.4C 로, Batch 1 에서 평균 충전 속도가 가장 빠른 정책이다.
- log 수명 기준 IQR 이상치는 세 배치 모두 없었다.

시사점 550 기준 이진 분류를 하면 학습 배치(Batch 1)의 단수명 셀은 1개뿐이라 단수명 클래스를 학습·검증할 수 없다. 반면 테스트(Batch 2)는 77% 가 단수명이다. → 회귀를 택한다.

Q1 Cycle Life 분포 : 기술통계 · log 변환 · 정책 내 변동

ISSUE) 어떤 척도로 다를 것인가, 정책만으로 얼마나 설명되는가



배치	평균	중앙값	표준편차	CV	왜도	첨도	log 왜도	log 첨도
Batch 1	921	842	401	0.43	2.06	3.62	1.31	1.32
Batch 2	566	472	222	0.39	1.57	1.12	1.30	0.24
Batch 3	1032	965	309	0.30	1.47	1.90	0.67	0.70


확인한 내용

- 세 배치 모두 평균이 중앙값보다 크고 왜도가 1.5~2.1 이다. 오른쪽 꼬리가 긴 분포다.
- log10 변환 후 왜도가 Batch 1 2.06 → 1.31, Batch 3 1.47 → 0.67 로 줄었다. 첨도도 함께 줄었다.
- 정책 내 변동 : 같은 정책 셀들의 평균으로 나머지 한 셀을 예측하면 MAPE 가 Batch 1 10.3%, Batch 2 7.9%, Batch 3 18.3% 다 (leave-one-out, 정책당 2개 이상).
- 정책 내 변동계수 중앙값은 Batch 1 5.6%, Batch 3 16.5% 다. 같은 조건으로 충전해도 셀마다 수명이 다르다.

시사점 타깃은 log10(cycle_life) 로 둔다. 충전 정책 정보만으로는 셀 간 차이(Batch 1 에서 약 10%)가 남으므로, 셀마다 측정되는 신호가 필요하다. → Q2·Q3

Q2 열화 곡선 : 방전 용량은 어떻게 감소하는가

ISSUE) 열화가 일정한가, 가속되는가, knee 는 언제 오는가




확인한 내용

- 초기에는 거의 평탄하다. cycle 2 → 100 방전 용량 변화의 중앙값은 +0.22% (Batch 1)로 오히려 조금 늘었다.
- EOL 직전 100 사이클의 감소 기울기는 초기(2~100) 기울기의 약 54배 (Batch 1 중앙값, Batch 3 는 61배)다.
- knee (곡선과 시작·끝을 잇는 직선 사이 거리가 가장 큰 지점)는 수명의 55~82% 지점(중앙값 71%)에 오고, knee 시점과 수명의 상관은 0.98 이상이다.
- 가장 이른 knee 도 cycle 244 라서 첫 100 사이클 안에서는 knee 를 볼 수 없다.
- cycle 2 용량과 log 수명의 상관은 Batch 1 에서 0.04 다.

시사점 예측 시점(100 사이클)에는 용량 값의 차이도, knee 도 아직 나타나지 않는다. 용량 추세 피쳐는 보조로만 쓰고, 100 사이클 안에서 보이는 다른 신호를 찾아야 한다.
→ Q3 ΔQ(V)

Q2 열화 곡선 : 수명으로 정규화한 모양과 구간별 속도

(ISSUE) 열화 경로가 셀마다 다른가, 시간 축만 다른가



용량 변화 (%/100 cycle)	0~20%	20~40%	40~60%	60~80%	80~100%
Batch 1	-0.22	-0.50	-0.82	-2.22	-7.98
Batch 2	+0.14	-0.40	-1.39	-4.16	-14.23
Batch 3	-0.23	-0.45	-0.63	-1.33	-6.22


확인한 내용

- 가로축을 cycle / cycle life 로 바꾸면 세 배치의 곡선이 비슷한 모양으로 모인다. 용량 손실 대부분이 수명의 마지막 20% 구간에서 일어난다.
- Batch 1 의 80~100% 구간 열화 속도는 0~20% 구간의 약 37배다.
- Batch 2 는 초기 20% 구간에서 용량이 오히려 늘었다 (+0.14%/100 cycle).
- 100 사이클은 Batch 1 증감값 수명(842)의 약 12%, Batch 2(472)의 약 21% 다. 같은 cycle 100 이라도 배치마다 열화 경로상 위치가 다르다.

시사점 열화 곡선의 모양은 비슷하고 수명이 시간 축의 길이를 정한다. 수명 예측은 이 시간 축을 맞추는 문제다. cycle 100 이 수명 대비 다른 지점이라 용량 추세 피쳐(기울기 등)는 배치 간 값이 달라질 수 있다 → 입력 분포 점검에서 확인.

Q3 $\Delta Q(V)$ 곡선 : 초기 사이클에서 차이가 보이는가

ISSUE) 용량이 거의 그대로인 초기에 방전 곡선 모양은 달라지는가





확인한 내용

- $\Delta Q_{100-10}(V) = Q_{100}(V) - Q_{10}(V)$. 단수명 셀일수록 음의 방향으로 크고 3.2~2.8V 구간의 골이 깊다. 장수명 셀은 0 근처에 머문다.
- $\log_{10} \text{var}(\Delta Q)$ 와 $\log$ 수명의 상관 : Batch 1 -0.95, Batch 2 -0.92, Batch 3 -0.81. 세 배치 모두에서 가장 강한 신호다.
- 배치마다 방전 곡선의 절대 위치가 다르다 (cycle 10, 2.0V 용량 중앙 값 1.067 / 1.059 / 1.052Ah). ΔQ 는 같은 셀 두 사이클의 차이이 이 오프셋이 상쇄된다.
- Batch 2 일반 셀은 Batch 1 회귀선보다 아래에 있다. 39개 중 11개는 ΔQ 분산이 Batch 1 최댓값보다 크다.

시사점 dq_var 를 핵심 피쳐로 둔다. log-log 에서 선형이므로 선형 모델이 맞는다. Batch 2 는 학습 범위 밖으로 외삽해야 하고, 같은 피쳐 값에서도 수명이 짧아 과대 예측 오차가 예상된다 (Gap 해석 시 근거).

Q3 $\Delta Q(V)$: 신호는 어느 전압대에서, 몇 사이클부터 생기는가

ISSUE) 왜 100 사이클인가, 5 사이클로는 안 되는가



확인한 내용



- 전압별로 보면 ΔQ 와 수명의 상관은 2.9V 부근에서 가장 크다 (Batch 1 0.90 @2.91V, Batch 2 0.85 @2.97V, Batch 3 0.76 @2.89V). 3.4V 부근은 0.08~0.37 로 약하다.
- ΔQ_{n-10} 의 n 을 늘리면 상관인 n = 30~40 부터 커지고 n = 100 에 서 세 배치 모두 가장 크거나 그에 가깝다.
- 논문 분류 과제가 쓰는 5 사이클 구간의 ΔQ_{5-4} 분산은 수명과 상관 이 거의 없다 (-0.25 ~ +0.03).

r (log var ΔQ , log life)	ΔQ_{5-4}	n=20	n=30	n=40	n=70	n=100
Batch 1	-0.01	-0.17	-0.71	-0.90	-0.89	-0.95
Batch 2	+0.03	-0.30	-0.59	-0.68	-0.67	-0.92
Batch 3	-0.25	+0.02	-0.43	-0.69	-0.79	-0.81

시사점 ΔQ 는 cycle 100 과 cycle 10 의 차이로 계산한다 (배치 공통으로 가장 강함). 5 사이클 데이터로는 같은 신호를 얻을 수 없어, 분류(5 사이클)보다 회귀(100 사이클)를 택한 결정을 뒷받침한다.

Q4 충전 조건(C-rate)과 수명

ISSUE) 빠른 충전은 정말 수명을 줄이는가



평균 충전 속도 = 0~80% SOC 구간 평균 C-rate = $0.8 / (Q1/C1 + (0.8-Q1)/C2)$, 정책 C1(Q1%)~C2



확인한 내용

- Batch 1 (평균 3.6~5.4C) : 평균 충전 속도와 log 수명의 상관 -0.78. 가장 느린 3.6C 셀 3개는 1852~2237, 가장 빠른 5.4C 셀 2개는 534 / 559 다.
- Batch 2·3 은 모든 정책의 평균 충전 속도가 **4.8C 로 같다** (10분 충전). 정책 간 차이는 단계 배분뿐이다.
- Batch 2 의 같은 정책에서 일반 셀과 newstructure 셀은 약 2배 차이 났다 (5.6C(26%)~4.5C : 448 vs 991).
- Batch 1 에서 평균 충전 속도와 dq_var 의 상관은 0.80 이다.

시사점 고속 충전은 Batch 1 에서 수명을 줄였다. 그러나 정책·충전 시간 피쳐는 테스트 배치에서 사실상 상수(4.8C, 충전 시간 중앙값 10.0~10.2분)라 학습한 관계를 쓸 수 없다. → 모델 입력에서 제외하고, 충전 조건의 영향은 이를 이미 반영한 AQ 피쳐로 받는다.

Q4 충전 조건 : 2단계 정책 분해

ISSUE) 평균 속도가 아니라 단계 배분이 수명을 바꾸는가




확인한 내용

- Batch 1 에서 log 수명과의 상관 : C1 -0.64, Q1 +0.35, C2 -0.08, 평균 충전 속도 -0.78. 1단계 전류와 그 지속 구간을 함께 반영한 평균 속도가 가장 잘 설명한다.
- 1단계 전류가 같으면 1단계를 오래 유지할수록 짧았다. 8C 는 Q1 15% → 25% → 35% 에서 평균 1008 → 676 → 608, 6C 는 30% → 60% 에서 1014 → 744.
- Batch 3 는 평균 속도가 모두 4.8C 인데 정책별 수명 중앙값 이 667 (3.7C(31%)-5.9C) 에서 1720 (4.8C(80%)-4.8C) 까 지 벌어졌다. 일정 전류 정책이 가장 길고, 높은 SOC 구간을 5.9C 로 충전하는 정책이 가장 짧았다.
- 여러 배치에 있는 정책도 배치마다 수명이 다르다.
4.8C(80%)-4.8C 평균 : Batch 1 753, Batch 2 일반 484 · newstructure 872, Batch 3 1588. 6C(60%)-3C : Batch 1 744, Batch 2 400.

시사점 단계 배분이 수명을 바꾸지만, 정책 조합이 배치마다 대부분 다르고(Batch 1 22종, Batch 2 9종, Batch 3 8종, 공통 2종) 같은 정책도 배치에 따라 수명이 최대 3배 차 이 난다. 정책 변수로 학습한 관계는 다른 배치에 옮길 수 없으므로 셀마다 측정되는 ΔQ 로 이 영향을 받는다.

Q5 상관관계 : 어떤 신호가 수명과 연관되는가

ISSUE) 배치를 바꿔도 유지되는 신호는 무엇인가




확인한 내용

- 세 배치에서 방향이 같은 피처 : ΔQ 분산·최솟값·평균 ($-0.76 \sim -0.95$), $\Delta Q@2.0V$ ($+0.49 \sim +0.70$), cycle 91~100 용량 기울기 ($+0.27 \sim +0.39$).
- 배치에 따라 부호가 바뀐 피처 : 충전 시간 ($+0.80 / -0.94 / +0.56$), 내부저항 cycle 2 ($+0.10 / -0.72 / +0.27$), 평균 온도 ($-0.52 / +0.39 / -0.04$).
- Batch 1에서 Spearman 상관도 같은 순서다 (dq_var -0.88, dq_2v +0.74). 소수의 장수명 셀이 만든 상관이다.

시사점 피처 선택은 Batch 1과 입력 분포(결측, 상수 여부)만으로 정한다. Batch 2·3 라벨로 본 상관은 일반화를 가능하는 참고용이며 선택 근거로 쓰지 않는다 (테스트 정보 누수 방지).

Q5 상관관계 : 다중공선성

ISSUE) 서로 겹치는 피처는 무엇인가




후보 11개	VIF	F3 (6개)	VIF
dq_min	1211	dq_var	3.9
dq_var	480	dq_skew	2.0
dq_mean	463	dq_kurt	1.6
chargetime_avg_2_6	295	dq_2v	5.5
avg_crate	291	qd_max_minus_c2	2.7
dq_kurt	18.6	fade_slope_91_100	2.1
fade_slope_2_100	10.6		
qd_max_minus_c2	6.3		
dq_skew	3.1		
qd_c2	2.7		
tavg_mean	2.1		

- ΔQ 분산·평균·최솟값끼리 $r = 0.99$, 충전 시간과 평균 충전 속도 $r = -0.99$, cycle 100-2 용량 차와 2~100 기울기 $r = 0.99$ (Batch 1).
- 겹치는 그룹마다 하나씩 남기면 VIF 가 5.5 이하로 내려간다.

시사점 $r = 0.99$ 그룹에서는 dq_var 하나, 용량 추세는 cycle 91~100 기울기 하나만 남긴다. 남은 상관은 ElasticNet / Ridge 규제로 안정화한다.

+ 배치 간 입력 분포 차이 (라벨 미사용)

ISSUE) 테스트 배치의 입력이 학습 분포 안에 있는가



각 피쳐를 Batch 1 평균·표준편차로 표준화. 수명값은 쓰지 않았다.

$\pm 2\sigma$ 밖 셀 비율	Batch 2	Batch 3
dq_var	3%	0%
dq_skew	10%	5%
dq_kurt	5%	0%
dq_2v	36%	8%
qd_max_minus_c2	46%	8%
fade_slope_91_100	62%	8%
qd_c2	59%	35%
tavg_mean	10%	45%
ir_c2	18%	40%

ΔQ 모양 피쳐(dq_var·skew·kurt)는 Batch 2·3 에서도 대부분 학습 범위 안에 있다. 용량 추세 피쳐는 Batch 2 에서 36~62% 가 벗어난다.

시사점 ΔQ 모양만 쓰는 F2 와 용량 추세를 더한 F3 를 모두 후보로 둔다. Batch 1 CV 에서 두 세트의 차이가 폴드 간 표준편차 안이면 **입력 이탈이 적은 F2 를 택한다** (테스트 라벨을 보지 않고 미리 정한 규칙).

→ EDA 시사점과 모델 전략의 연결

EDA 에서 확인한 것	결정	반영 위치
Q1 : 550 미만 셀이 Batch 1 에 1개, Batch 2 에 30개	분류 대신 회귀	Task
Q1 : 왜도 1.5~2.1, log 변환 후 감소 · 정책 내 변동 약 10%	타깃 $\log_{10}(\text{cycle_life})$, 셀 단위 신호 필요	Target
Q2 : 100 사이클까지 용량 변화 +0.22%, 가장 이른 knee 244	용량 피쳐는 보조	Feature F3
Q3 : $\log \text{var}(\Delta Q)$ $r = -0.81 \sim -0.95$, log-log 선형, 배치 오프셋 상쇄	dq_var 핵심, 선형 계열 중심	Feature F1~F3, Model
Q3 : 신호는 $n = 30 \sim 40$ 부터, $n = 100$ 에서 최대. ΔQ_{5-4} 는 신호 없음	ΔQ_{100-10} 사용, 예측 시점 cycle 100	Feature, Task
Q3 : Batch 2 는 수명·피쳐 모두 Batch 1 범위 밖	외삽 가능한 선형 모델 주 후보, 트리는 비교용	Model
Q4 : Batch 2·3 평균 충전 속도 4.8C 고정, 같은 정책도 배치마다 수명 차이 (4.8C : 484 ~ 1588)	정책·충전 시간 피쳐 제외	Feature
Q5 : r 0.99 그룹, VIF 최대 1211	그룹당 1개 + 규제 모델	Feature, Model
품질 : Batch 2 내부저항 셀 단위 결측 6개	내부저항 제외	Feature
입력 분포 : 용량 추세 피쳐가 Batch 2 에서 36~62% 이탈	F2 / F3 선택 규칙을 미리 정함	Feature 선택
수명 검증 : 이어 측정 셀 수명 잘림 · 같은 정책 셀 여러 개	공식 기준 보정·제외, 정책 단위 분할	Pipeline, Validation

S1 모델링 전략 : 태스크 · 타깃 · 피쳐 세트

	회귀 (선택)	분류 (550 기준)
학습 (Batch 1, 41개)	534 ~ 2237 연속값	단수명 1개 vs 장수명 40개
테스트 (Batch 2, 39개)	392 ~ 1186, 30개가 학습 범위 아래	단수명 30개 (77%)
입력 신호	ΔQ_{100-10} $r = -0.81 \sim -0.95$	ΔQ_{5-4} $r = -0.25 \sim +0.03$
판단	외삽 부담이 있지만 학습·검증 가능	단수명 클래스 학습 불가

세트	피쳐	역할
F1 분산	dq_var	기준선
F2 ΔQ 모양	dq_var, dq_skew, dq_kurt	주 후보 (입력 이탈 적음)
F3 ΔQ + 용량	F2 + dq_2v, qd_max_minus_c2, fade_slope_91_100	주 후보 (VIF 5.5 이하)
F4 전체	F3 + chargetime_avg_2_6, tavg_mean, ir_c2	비교용 (테스트 입력 상수·결측)

dq_* : ΔQ_{100-10} (V) 통계량의 log10 |값| (var 분산, skew 왜도, kurt 첨도, 2v 는 2.0V 지점 값). qd_max_minus_c2 : cycle 2~100 최대 용량 - cycle 2 용량. fade_slope_91_100 : cycle 91~100 용량 선형 기울기. 계산 : src/features.py

타깃 : $\log_{10}(\text{cycle_life})$. 예측 후 10^x 로 되돌려 MAPE 계산.

예측 시점 : cycle 100 까지의 데이터만 사용.

S2 모델링 전략 : 후보 모델과 선택 근거


모델	역할	선택 근거 (EDA 연결)	튜닝 범위
선형회귀 (F1)	기준선	dq_var 하나와 log 수명이 선형 (Q3). 이보다 나아지지 않으면 피처를 늘릴 이유가 없다.	없음
ElasticNet	주 후보	학습 셀 32개, 피처 간 상관 (Q5) → L1·L2 규제로 선택과 안정성을 함께 얻는다. 선형이라 학습 범위 밖으로 외삽 가능 (Q3)	alpha 1e-4~1, l1_ratio 0.1~1.0
Ridge / Lasso	규제 비교	ElasticNet 의 양 끝. 어느 쪽 규제가 맞는지 확인	alpha
RandomForest	비선형 비교	피처와 수명의 비선형 관계 확인용. 다만 예측값이 학습 타깃 범위 안(Batch 1 최솟값 534 이상)에 묶인다. Batch 2 일반 셀 30개를 534 로 예측해도 평균 오차 18.6%	min_samples_leaf, max_features
XGBoost	비선형 비교	위와 같은 한계. 소표본에서 과적합 여부 확인용	max_depth 2~3, min_child_weight

답러닝은 셀 41개 규모에서 쓰지 않는다. 최종 모델은 Batch 1 CV 로 고르고, 고른 설정으로 Batch 1 전체를 다시 학습해 Batch 2 에 적용한다.

시사점 외삽이 필요한 테스트 구조(Q1·Q3)라서 선형 규제 모델을 주 후보로 두고, 트리 계열은 같은 피처로 비교만 한다.

S3 사전 점검 : Batch 1 교차검증 (Valid · Test 미사용)

ISSUE) 전략이 Batch 1 안에서 성립하는가




Batch 1 train 32셀 (17개 정책). 정책 단위 GroupKFold(5), 튜닝은 각 폴드 안의 GroupKFold(4) 로 (nested). 막대 = 평균, 오차막대 = 폴드 간 표준편차.

CV MAPE (%)	F1	F2	F3	F4
Linear	8.9	9.4	9.0	9.7
ElasticNet	9.0	8.9	8.7	9.9
Ridge	9.0	8.6	8.2	10.4
Lasso	9.0	8.8	8.7	10.0
RandomForest	15.3	14.2	15.0	13.5
XGBoost	16.4	16.0	17.1	15.8

- 선형 계열 8.2~10.4%, 트리 계열 13.5~17.1%.
- 충전 시간·온도·내부저항을 더한 F4 는 선형 모델에서 F3 보다 나뉘었다.
- F2 와 F3 의 차이(Ridge 0.4%p)는 폴드 간 표준편차(약 3%p) 안이다.
- 누수 점검 : 같은 조건에서 무작위 KFold 는 10.0%, 정책 단위는 8.7% 였다. 무작위 분할이 낙관적으로 나오지는 않았지만, 새 정책 셀을 예측하는 상황에 맞춰 정책 단위 분할을 유지한다.

시사점 Batch 1 안에서는 선형 규제 모델 + ΔQ 피쳐 전략이 성립한다. F2/F3 는 미리 정한 규칙에 따라 DAY 2 Valid 확인 후 확정한다. 원논문 9.1% 와 숫자가 비슷하지만 데이터 분할이 달라 같은 비교는 아니다.

S4 파이프라인과 검증 설계



노션 포맷 항목	이번 설계에서의 의미
Train (Batch 1 CV)	train 32셀, 정책 단위 GroupKFold(5) 평균 MAPE
Valid (Batch 1 Hold-out)	정책 5개 · 9셀 (534~1074). 수명 순위 5구간에서 정책 1개씩 추출
Test (Batch 2)	39셀, 최종 모델로 한 번만
Gap (Train-Valid)	과적합 확인
Gap (Valid-Test)	배치 간 일반화. 일반 / newstructure 셀 나눠 해석
Gap (Target-Test)	원논문 9.1% 대비. 테스트셋이 다름을 비교에 명시

Final Reminders 반영

- 분할을 가장 먼저, 스케일러는 Pipeline 안에서 train 폴드에만 fit
- Valid 9셀 중 2셀(534, 559)은 train 최솟값(599)보다 짧아 Batch 2 와 같은 외삽 상황을 미리 본다
- test 는 마지막에 한 번, 피쳐 선택에 Batch 2·3 라벨 미사용
- random_state = 42, requirements.txt 버전 고정

S5 위험 요인과 DAY 2 계획

위험	근거	대응
Batch 2 과대 예측	일반 셀 30개가 학습 범위 아래, 같은 dq_var 에서 수명이 짧음 (Q3)	log 타깃 + 선형 모델. 오차를 일반 / newstructure 로 나눠 원인 제시
입력 분포 이탈	용량 추세 피쳐 36~62% 가 $\pm 2\sigma$ 밖	F2 / F3 선택 규칙 사전 고정, Gap 분석 시 피쳐별 기여 확인
작은 표본	train 32셀, 정책당 1~3셀	nested CV, 단순 모델 우선, 표준편차 함께 보고
Batch 3 분포 차이	전부 newstructure, 온도 $+1.6\sigma$, 내부저항 -1.9σ	추가 검증, Gap(Batch2-Batch3) 원인 분석
원논문 비교	Batch 2 는 논문 124셀에 없음	Gap(Target-Test) 비교에 명시

DAY 2 할 일

- 03_modeling.ipynb, src/train.py : 최종 모델 학습과 포맷 성능표 (results/model_performance.csv)
- 오류 분석 : 가장 크게 틀린 셀의 공통점 (정책, newstructure, 입력 이탈 정도)
- Batch 3 추가 검증과 Gap(Batch2-Batch3)
- ESS 도메인 해석 : 교체 시점 계획에 쓸 수 있는 오차 수준, 배포 전 필요한 것
- README 정리 (GitHub public)